



DOCUMENT & WEB SÉMANTIQUE

Reconnaissance de Formes

Auteurs :

Julien BARON

Grégoire GUTZWILLER

Evaluateur :

Clément CHATELAIN

Cadre du projet :

L'objectif du projet est d'appréhender les différentes étapes d'un système de reconnaissance de formes à travers le développement d'une chaîne de reconnaissance de chiffres manuscrits sous MATLAB.

Date :

06 Mars 2015

Table des matières

Introduction	2
1 Les données	3
2 Découpe des imagerie	5
3 Apprentissage du modèle	6
4 Classification	7
4.1 Reconnaissance avec distance euclidienne minimale sur modèle moyen	7
4.2 Décision par la méthode des k plus proches voisins	8
4.3 Méthode des k-ppv avec d'autres distances	8
4.4 Utilisation d'autres caractéristiques	8
4.5 Combinaison de classifieurs	9
4.6 Résultats finaux	9
5 Conclusion	11

Introduction

Au sein de l'EC Document, nous avons été amenés à travailler avec M. Chatelain sur les méthodes de reconnaissance d'écriture. Ces méthodes permettent, entre autres, de reconnaître de l'écriture humaine afin de la transformer en caractère numérique lisible par un ordinateur. L'objectif de ce projet est donc de mettre en pratique ce que nous avons vu en cours sur la reconnaissance de formes et de nous livrer à un exercice de recherche sur les meilleures façons de reconnaître des chiffres écrits à la main.

Nous allons donc avoir besoin de créer un programme MATLAB permettant, à partir d'une base d'apprentissage, de déterminer les nombres présents dans une base de test. Vous trouverez donc dans ce rapport toute notre démarche pour atteindre un résultat le plus proche possible de la perfection.

Chapitre 1

Les données

Ce que nous appelons données consiste en fait en l'ensemble de la base de test, et de la base d'apprentissage. Elles nous sont données sous la forme d'images que voici.




FIGURE 1.1 – Base d'apprentissage du projet (200 chiffres)

0 0 0 0 0 0 0 0 0 0
 1 1 1 1 1 1 1 1 1 1
 2 2 2 2 2 2 2 2 2 2
 3 3 3 3 3 3 3 3 3 3
 4 4 4 4 4 4 4 4 4 4
 5 5 5 5 5 5 5 5 5 5
 6 6 6 6 6 6 6 6 6 6
 7 7 7 7 7 7 7 7 7 7
 8 8 8 8 8 8 8 8 8 8
 9 9 9 9 9 9 9 9 9 9

FIGURE 1.2 – Base de test du projet (100 chiffres)

Chapitre 2

Découpe des imageries

Comme nous le voyons sur les figures représentant les bases de chiffres qui nous sont données, les chiffres ne sont pas encore découpés. Pour procéder au découpage des imageries, nous avons utilisé les fonctions données par M. Chatelain. Celles-ci ont été condensées en un fichier `crop_image.m`. Celui-ci contient une fonction MATLAB permettant de renvoyer un tableau d'images croppées.

Chapitre 3

Apprentissage du modèle

Pour réaliser notre projet, nous pouvions utiliser tout un panel de caractéristiques adaptées à la reconnaissance de formes. Ces caractéristiques permettent d'obtenir des informations sur chaque échantillon et ainsi de créer une « carte d'identité » pour chaque chiffres. Il sera ainsi plus facile de comparer la base d'apprentissage aux échantillons de la base de test.

Les caractéristiques proposées par M. Chatelain dans l'énoncé du projet sont au nombre de deux. La première consiste en l'élaboration de profils pour chaque imagerie. C'est la première méthode que nous avons décidé d'implémenter. Suite à une petite étude que nous avons fait, nous avons constaté que la méthode était optimale pour un nombre de profils de 10.

La seconde méthode consiste en l'étude de densité de pixels au sein de l'imagerie. Encore une fois, nous avons déterminé que les meilleurs paramètres pour l'utilisation de cette méthode consiste à diviser l'imagerie en 10 rangées pour 5 colonnes.

Après extraction complète du modèle, celui-ci se trouve dans une matrice qui sauvegarde pour chaque imagerie toutes les caractéristiques. Cette matrice est enregistrée dans le fichier `modeleRDF.mat`.

Chapitre 4

Classification

Nous devons maintenant élaborer des classifieurs pour classer les imagerie de la base de test dans différentes classes de chiffres. Nous avons mis en place deux méthodes de classification. La première se base sur la distance euclidienne minimale du modèle par rapport à une imagerie de la base de test. La seconde consiste à réaliser la méthode des k plus proches voisins. Nous nous sommes exclusivement concentrés sur les taux de réussite en TOP1.

4.1 Reconnaissance avec distance euclidienne minimale sur modèle moyen

Cette méthode de classification consiste à comparer notre imagerie de test avec le modèle moyen pour chaque classe. Avec cette méthode, nous obtenons la matrice de confusion suivante.

	0	1	2	3	4	5	6	7	8	9
0	1	0	0	0	0	0	0	0	0	0
1	0	0.9	0.1	0	0	0	0	0	0	0
2	0	0	0.9	0	0	0	0.1	0	0	0
3	0	0	0	0.5	0	0	0	0	0	0.5
4	0	0	0	0	0.9	0	0.1	0	0	0
5	0	0	0	0	0	1	0	0	0	0
6	0	0	0	0	0	0	1	0	0	0
7	0	0	0	0.1	0	0	0	0.9	0	0
8	0	0.2	0	0	0	0	0	0	0.8	0
9	0	0	0	0	0	0	0	0.1	0.3	0.6

FIGURE 4.1 – Matrice de confusion en TOP1 pour cette méthode

Ceci nous donne 85% de bons résultats avec ce classifieur.

Si nous choisissons en revanche de ne pas utiliser le modèle moyen pour chaque classe mais, au contraire, d'utiliser la norme euclidienne sur chaque élément du modèle, nous obtenons un résultat de 92% en TOP1. Voici les résultats pour chaque classe.

Nous constatons que les chiffres soulevant le plus de problèmes sont le 9 et le 3. Il faudra donc trouver une méthode pour mieux les repérer.

0	1	2	3	4	5	6	7	8	9
1	1	1	0.7	1	1	1	0.9	1	0.6

FIGURE 4.2 – Résultat sans moyenner les classes

4.2 Décision par la méthode des k plus proches voisins

Grâce au cours de Data-mining, nous savons écrire l'algorithme des k-ppv. Mais comment déterminer le nombre de plus proches voisins à sélectionner ? Nous avons choisi, pour répondre à cette problématique, d'essayer avec plusieurs k différents.

0.92	0.93	0.90	0.91
------	------	------	------

FIGURE 4.3 – Bons résultats en TOP1 selon la valeur de k (k = 1, 2, 3, 4)

Ceci nous amenant en toute logique à utiliser un k égal à 2.

4.3 Méthode des k-ppv avec d'autres distances

Pour essayer d'améliorer nos résultats, nous avons voulu essayer d'utiliser de nouvelles distances. Nous nous sommes donc intéressés dans un premier temps à la distance de Manhattan. Celle-ci nous donne les résultats suivants.

0	1	2	3	4	5	6	7	8	9
1	1	1	0.9	0.9	1	1	0.9	0.9	0.6

FIGURE 4.4 – Résultat avec la distance de Manhattan

Ceci donnant un résultat moyen de 92 %, ce qui est insuffisant comparé aux méthodes précédentes.

Nous avons ensuite essayé avec la distance de Minkowski de degré 3. Celle-ci nous donne les résultats suivants.

0	1	2	3	4	5	6	7	8	9
1	1	1	0.9	1	1	1	1	0.9	0.6

FIGURE 4.5 – Résultat avec la distance de Minkowski

Ceci donnant un résultat moyen de 94 %, ce qui est déjà un meilleur résultat. C'est donc très encourageant.

4.4 Utilisation d'autres caractéristiques

A cette étape du projet, nous avons choisi d'utiliser d'autres caractéristiques. En effet, les tests réalisés sur les classifieurs ne montrait pas de grosses améliorations.

Nous nous sommes intéressés à la trace. Il s'agit en quelque sorte, de réaliser un profil sur un nombre de traits égal au nombre de pixel de l'image. La figure suivante permet de visualiser les effets de notre fonction `traceGD.m`.




FIGURE 4.6 – Exemples de résultats de la fonction trace

kppv/trace Gauche	0.88
DEG/trace Gauche	0.87
kppv/trace Droite	0.93
DEG/trace Droite	0.93

FIGURE 4.7 – Taux de bons résultats avec la caractéristique trace

Les résultats avec cette caractéristique sont les suivants :

Nous avons aussi réalisé une méthode de classification par les kppvs avec l'utilisation d'une trace Gauche-Droite qui donne des résultats peu intéressants mais qui reconnaît bien les 9. Il s'agirait donc de l'utiliser avec un classifieur plus efficace pour obtenir un très bon taux de reconnaissance.

4.5 Combinaison de classifieurs

Nous allons donc essayer de combiner les classifieurs kppv/Minkowski3 avec la DEG/trace Droite et la DEG/trace Gauche-Droite. Nous choisirons les paramètres optimaux dans le maximum de cas.

La combinaison de ces classifieurs commence par les classifieurs les plus précis pour terminer avec le moins efficace mais qui discrimine mieux les 9 des 8.

Dans chaque cas, on vérifiera si le résultat obtenu est certain avec le classifieur utilisé.

S'il ne l'est pas, on passe au classifieur suivant pour essayer de déterminer avec exactitude la classe.

4.6 Résultats finaux

L'utilisation d'une combinaison de classifieurs nous a permis d'obtenir de très bons résultats. En effet, nous avons réussi à obtenir un taux de bonnes réponses de 98%, voir le vecteur de résultat suivant.

0	1	2	3	4	5	6	7	8	9
1	1	1	0.9	1	1	1	1	0.9	1

FIGURE 4.8 – Résultat des classifieurs combinés

Les confusions restantes sont obtenues sur un 3 et un 8 que notre chaîne de reconnaissance de formes confond avec des 9.

Chapitre 5

Conclusion

Nous venons de voir que la reconnaissance de formes est sensible aux paramètres initiaux et aux caractéristiques utilisées. En combinant des méthodes plutôt basiques et pas toujours efficaces globalement, on peut créer un très bon classifieur.

Ce fut un projet passionnant et qui a révélé chez nous un certain enthousiasme pour la reconnaissance de formes. Nous avons pris un certain plaisir à réaliser ces algorithmes pour tenter d'obtenir le meilleur résultat possible. Obtenir un résultat final de 98 % de bonnes réponses est pour nous une grande réussite.

Nous vous invitons maintenant à consulter le rapport MATLAB, généré grâce au fichier *squelette.m* et aux fonctions que nous avons codées, pour voir plus en détail notre travail.